

식물 내 물질 네트워크 분석

신동욱, 송의종

October 30, 2025

1. 분석 목적 및 개요

이 분석에서는 식물 내 물질 양 데이터를 이용하여, 식물 내 물질 네트워크를 추정하고 관심 변수(호르몬 변수)가 추정된 네트워크 상에서 허브라고 판단할 수 있는지 알아보고자 한다.

구체적으로, 식물 내 네트워크 추정을 위한 방법으로 부분 상관계수 (Partial correlation) 기반의 가우시안 그래피컬 모델 (Gaussian graphical model), 논파라노말 그래피컬 모델 (Nonparanormal graphical model) 을 이용하였다. 이후 각 추정된 노드의 허브 점수인 차수 (Degree), 가중 차수 (Strength), 고유벡터 중심성 (Eigenvector centrality), 매개 중심성 (Betweenness centrality), 근접 중심성 (Closeness centrality)을 이용하였다. 마지막으로 관심 변수들의 추정된 네트워크 상 허브 점수의 분위수를 판단하여, 다른 변수들 대비 어느정도 분위에 위치한지 알아보고자 하였다.

2. 네트워크 추정 방법

이 절에서는 분석에 사용한 네트워크 추정 방법에 대해서 소개하고, 각 방법론의 이해를 돕기 위한 직관적인 해석을 서술하였다.

2.1 가우시안 그래피컬 모델

가우시안 그래피컬 모델의 정의

평균이 0, 공분산 행렬이 Σ 인 p -차원 가우시안 분포를 따르는 확률 벡터 X 가 주어졌다고 가정하자.

$$X = (X_1, \dots, X_p)^\top \sim \mathcal{N}_p(0, \Sigma).$$

이 때 공분산 행렬의 역행렬 $\Theta = \Sigma^{-1}$ 를 정밀도 행렬(Precision matrix)이라고 정의한다.

각 변수를 나타내는 노드 집합 $V = \{1, \dots, p\}$ 에 대해 정밀도 행렬의 각 (i, j) 비대각 원소 Θ_{ij} 가 0이 아니면 연결, 0이라면 연결되지 않는 엣지의 집합 E 를 생각할 수 있다.

$$(i, j) \notin E \iff \Theta_{ij} = 0.$$

이러한 그래프 $G = (V, E)$ 에 대해서, (X, G) 를 그래프 G 에 대한 가우시안 그래피컬 모델을 따른다고 정의한다.

부분 상관계수

다음으로 가우시안 그래피컬 모델과 밀접한 관련이 있는 부분 상관계수에 대해서 소개하고자 한다. 부분 상관계수는 두 변수간 선형적 관계를 고려하는 일반적인 상관계수와 달리 조건으로 주어지는 다른 변수들을 고려한다. 모든 다른 변수 $X_{V \setminus \{i, j\}}$ 를 조건으로 고려한 X_i 와 X_j 사이의 부분 상관계수 $\rho_{ij \cdot V \setminus \{i, j\}}$ 는 다음으로 주어진다.

$$\rho_{ij \cdot V \setminus \{i, j\}} = \text{Corr}(R_{X_i | X_{V \setminus \{i, j\}}}, R_{X_j | X_{V \setminus \{i, j\}}}).$$

여기서 Corr 은 상관계수를 의미하며, $R_{X_i | X_{V \setminus \{i, j\}}}$ 는 X_i 를 $X_{V \setminus \{i, j\}}$ 로 선형 회귀를 수행한 후 설명되지 않는 잔차를 의미한다. 즉, 부분 상관 계수는 다른 변수가 선형적으로 설명하지 못하는 부분 사이의 피어슨 상관계수를 의미한다고 해석할 수 있다.

가우시안 그래피컬 모델의 성질

가우시안 그래피컬 모델의 정밀도 행렬의 각 (i, j) 비대각 성분 Θ_{ij} 으로 부분 상관계수를 닫힌 형식으로 계산할 수 있다.

$$\rho_{ij \cdot V \setminus \{i, j\}} = -\frac{\Theta_{ij}}{\sqrt{\Theta_{ii}\Theta_{jj}}}.$$

즉, 가우시안 그래피컬 모델의 네트워크는 부분 상관계수가 0이면 엣지가 존재하지 않고, 부분 상관계수가 0이 아니면 엣지가 있음을 나타내는 그래프이다. 더 나아가 가우시안 분포는 부분 상관 계수가 0인 것이 두 변수가 다른 변수가 주어졌을 때 서로 조건부 독립인 것과 동치이므로 다음의 강력한 성질이 존재한다.

$$(i, j) \notin E \iff X_i \perp X_j \mid X_{V \setminus \{i, j\}}.$$

상관계수를 이용한 네트워크와 가우시안 그래피컬 모델의 가장 큰 차이점으로, 상관계수를 이용한 네트워크는 두 변수가 다른 변수를 통해서 서로 영향을 주고 받는 경우 두 변수 간 엣지가 존재한다고 판단한다. 그러나 가우시안 그래피컬 모델은 타 변수를 통해서만 의존적인 두 변수 간에는 엣지가 없다고 판단한다.

가우시안 그래피컬 모델의 추정

가우시안 그래피컬 모델의 추정은, 표본 공분산 $\hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n X^{(i)}(X^{(i)})^\top$ 으로부터 모집단의 정밀도행렬 $\Theta = \Sigma^{-1}$ 추정하는 문제로 생각할 수 있고, 특히 비대각 원소의 영 패턴을 복원하는 문제로 생각할 수 있다. 그러나 표본의 불확실성으로 인해 $\hat{\Theta} = \hat{\Sigma}^{-1}$ 의 비대각 원소는 일반적인 경우 0이 되지 않으며, 특히 고차원($p \gg n$)에서는 표본 공분산의 역행렬이 존재하지 않는다.

따라서 위 두 문제를 해결하기 위해 Friedman et al. [2008]에서 제안된 그래피컬 라쏘 (Graphical lasso) 방법을 표준적으로 많이 사용하며, 아래와 문제의 해로서 정의된다.

$$\hat{\Theta} = \arg \min_{\Theta \succ 0} \left\{ -\log \det(\Theta) + \text{tr}(\hat{\Sigma}\Theta) + \lambda \|\Theta\|_{1,\text{off}} \right\}.$$

여기서 λ 는 패널티 파라미터, $\|\Theta\|_{1,\text{off}} = \sum_{i \neq j} |\Theta_{ij}|$ 는 비대각 원소의 영 성분을 유도하는 패널티 항을 의미한다.

본 분석에서는 위의 그래피컬 라쏘를 이용하여 물질간 네트워크를 추정하였으며, 패널티 항의 선택으로는 Foygel and Drton [2010]에서 제안한 EBIC (Extended bayesian information criterion) 기반 패널티 선택 방법을 이용하였다.

2.2 논파라노말 그래피컬 모델

논파라노말 그래피컬 모델의 정의

확률 벡터 $X = (X_1, \dots, X_p)^\top$ 에 대해 각 좌표별 단조 증가 함수 $f_j : \mathbb{R} \rightarrow \mathbb{R}$ 가 존재하여 다음이 성립한다고 가정하자.

$$Z = (f_1(X_1), \dots, f_p(X_p))^\top \sim \mathcal{N}_p(0, \Sigma).$$

이러한 Z 의 정밀도 행렬 $\Theta = \Sigma^{-1}$ 의 영 패턴으로 생성되는 그래프를 고려할 때, (X, G) 가 논파라노말 그래피컬 모델을 따른다고 정의한다 (Liu et al. [2009]). 논파라노말 그래피컬 모델은 $f_j(x) = x$ 이면 가우시안 그래피컬 모델과 같아지고, 따라서 가우시안 그래피컬 모델의 일반화로 볼 수 있다. 직관적으로 논파라노말 그래피컬 모델은 각 변수들이 가우시안을 따른다고 보기 어려울 때, 가우시안으로 단조변환한 후 가우시안 그래피컬 모델을 적용하는 방법으로 이해할 수 있다.

논파라노말 그래피컬 모델의 성질

논파라노말 그래피컬 모델은 가우시안 그래피컬 모델로부터 다음의 성질을 갖는다.

$$(i, j) \notin E \iff Z_i \perp Z_j \mid Z_{V \setminus \{i, j\}} \iff X_i \perp X_j \mid X_{V \setminus \{i, j\}}.$$

단조변환된 Z 가 나타내는 정밀도 행렬 Θ 로부터 얻어진 부분 상관계수는 원자료 X 에서의 부분 상관계수와 수치가 달라져 부분 상관계수로서의 정확한 의미는 희석되나, 부분 상관계수의 대소관계와 영 패턴은 보존되므로 그래프 G 는 여전히 원자료 X 의 조건부 독립성을 보존한다.

논파라노말 그래피컬 모델의 추정

논파라노말 그래피컬 모델의 추정을 위해서는 먼저 X 로부터 관측되지 않은 잠재변수 Z 를 생성해야 한다. 이를 위해 X_j 의 경험적 누적분포 $\hat{F}_j(x)$ 를 추정한 뒤, 표준 가우시안 분포의

누적분포 Φ 를 이용하여 $\hat{f}_j$ 를 먼저 추정한다. 이후 추정된 $\hat{f}_j$ 를 이용하여 Z 를 생성한다.¹

$$\hat{f}_j(x) = \Phi^{-1}(\hat{F}_j(x)), \quad \hat{Z}_j^{(i)} = \hat{f}_j(X_j^{(i)}).$$

이러한 잠재변수를 이용해 잠재 공분산행렬 $\hat{\Sigma} = \sum_{i=1}^n \hat{Z}^{(i)}(\hat{Z}^{(i)})^\top$ 을 추정하고, 다시 이를 통해 그래피컬 라쏘로 $\hat{\Theta}$ 를 추정한다.

$$\hat{\Theta} = \arg \min_{\Theta \succ 0} \left\{ -\log \det \Theta + \text{tr}(\hat{\Sigma}\Theta) + \lambda \|\Theta\|_{1,\text{off}} \right\}.$$

이 분석에서는 논파라노말 그래피컬 모델의 패널티 파라미터 역시 가우시안 그래피컬 모델과 같은 EBIC 방법으로 패널티 파라미터 λ 를 선택하였다.

3. 허브 점수

이 절에서는 추정된 네트워크에서 각 노드의 허브성을 판단하기 위한 지표들을 간략히 정리한다. 분석에서 인접행렬 W 는 각 네트워크 추정량의 엣지를 통해서 정의되며, 가중 인접행렬 W^* 는 각 방법론에서 추정된 부분 상관계수 절대값을 이용한다.

$$W_{ij} = \mathbf{1}\{(i, j) \in E\}, \quad W_{ij}^* = \frac{|\hat{\Theta}_{ij}|}{\sqrt{\hat{\Theta}_{ii}}\sqrt{\hat{\Theta}_{jj}}}.$$

차수 (Degree)

노드 i 에 연결된 다른 노드의 수로서, 다음과 같이 정의된다.

$$H_i^D = \sum_j \mathbf{1}\{W_{ij} > 0\}.$$

차수는 허브노드를 판단하는 가장 기본적인 지표로서, 단순히 연결된 노드가 많을수록 허브라고 판단한다.

가중 차수 (Strength)

노드 i 에 걸린 가중치의 합으로서, 다음과 같이 정의된다.

$$H_i^{WD} = \sum_j W_{ij}^*.$$

가중 차수는 연결된 노드가 많을 뿐 아니라, 연결된 강도가 강할수록 허브라고 판단한다.

¹본 분석에서는 R 패키지 huge에서 제공하는 경험적 누적분포의 축소추정량을 사용하였다.

고유벡터 중심성 (Eigenvector centrality)

가중 인접행렬 W^* 의 최대 주성분에 대응되는 주고유벡터 성분으로, λ^* 을 W^* 의 최대 고유값이라 했을 때 다음과 같이 정의된다.

$$H_i^E = \mathbf{v}_i, \quad \text{for } \lambda^* \mathbf{v} = W^* \mathbf{v}.$$

고유벡터 중심성은 단순히 다른 노드들과의 연결성만을 고려하는게 아닌, 영향력이 큰 노드에 많이 연결되어 있을 수록 허브라고 판단한다.

매개 중심성 (Betweenness)

모든 쌍 (s, t) 사이 최단경로 수를 σ_{st} , 그 중 i 를 지나는 경로 수를 $\sigma_{st}(i)$ 라 할 때 다음과 같이 정의된다.

$$H_i^B = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}.$$

분리된 그래프에서 경로가 없으면 $\sigma_{st} = 0$ 이므로 해당 항은 0으로 둔다. 매개 중심성은 다른 노드로 이동할 수 있는 경유지일수록 허브노드라고 판단하는 지표이다.

근접 중심성 (Closeness)

모든 쌍 (s, t) 사이의 최단 거리를 $d(s, t)$ 로 정의했을 때, 다음과 같이 정의된다.

$$H_i^C = \frac{n-1}{\sum_{s \neq t} d(s, t)}.$$

분리된 그래프에서는 최단거리가 무한대로 정의되므로 아래의 식으로 대체한다.

$$H_i^C = \frac{1}{n-1} \sum_{s \neq t} \frac{1}{d(s, t)}, \quad \text{for } 1/\infty = 0.$$

근접 중심성은 다른 노드로 이동할 때의 거리가 짧을수록 허브 노드라고 판단하는 지표이다.

4. 분석 결과

이 절에서는 앞서 소개한 추정 방법과 허브 노드 지표를 이용한 호르몬 변수들의 허브 점수를 추정하고, 상대적인 허브 점수가 다른 노드에 비해 어느정도에 위치하고 있는지에 대한 결과를 소개하고자 한다.

데이터 설명

분석에 사용한 데이터는 $p = 1444$ 개의 물질 변수(호르몬 변수 3개 포함)에 대한 각 식물의 $n = 101$ 개의 관측치로 이루어져 있다. 본 분석에서는 컨트롤 그룹을 포함하였으며,




Figure 1: 가우시안 그래피컬 모델 각 허브 점수 별 호르몬 변수의 분위수

충분한 표본 수 확보를 위해 각 곤충의 그룹 변수는 고려하지 않고 전체 샘플에서 분석을 진행하였다.

가우시안 그래피컬 모델 결과

가우시안 그래피컬 모델에서는 모든 3개의 호르몬 변수 (JA, SA, ABA)가 모든 허브 점수 상에서 상위 90% 이상을 차지한 경우가 존재하지 않았다. 또한 허브 점수의 분포가 매개 중심성을 제외하면 대칭형에 가까운 것으로 판단되고, 이를 통해 전체적으로 허브라고 볼 수 있는 노드가 적다고 유추해 볼 수 있겠다.

논파라노말 그래피컬 모델 결과

논파라노말 그래피컬 모델에서는 차수를 기준으로 한 점수에서 JA와 SA가 높은 허브 점수를 갖는 것을 확인할 수 있었다. 그러나 그 외 점수에서는 모든 호르몬 변수가 상위 90% 이상을 차지한 경우가 가중 차수를 제외하면 존재하지 않는다. 그 외의 패턴은 가우시안 그래피컬 모델의 경우와 유사하다.

5. 결론 및 한계

본 분석에서는 가우시안 그래피컬 모델과 논파라노말 그래피컬 모델을 이용하여 관심 변수가 네트워크 상에서 허브노드에 위치하는지 여부를 경험적으로 추정하였다. 분석 결과로는 대부분의 지표에서 호르몬 변수는 허브 노드라고 보기 어려운 점수 분위수를 가진 것으로




Figure 2: 논파라노말 그래피컬 모델 각 허브 점수 별 호르몬 변수의 분위수

판단된다. 그러나 논파라노말 그래피컬 모델에서 2개의 호르몬 변수가 높은 차수 기준 허브 점수를 가지는 것으로 분석되었다.

본 분석의 한계는 다음과 같다. 먼저, 허브 노드의 판단이 경험적인 수치에 의존하여 통계적인 근거가 부족하다. 최근 주어진 네트워크에서 관심 노드가 허브노드라는 가설을 위한 검정법이 몇몇 통계 연구에서 제안된 것으로 확인하였으나, 현재 데이터에는 적용하기 어려운 방법으로 판단되었다.

두 번째로, 물질의 각 주변분포는 가우시안을 따른다고 보기 어렵다. 이를 극복하기 위해 논파라노말 그래피컬 모델을 이용한 분석을 진행하였으나, 논파라노말 그래피컬 모델은 그 추정 방법에 따라서 재현율이 떨어지는 경우가 잦아 대체적인 강건한 방법이 필요하다.

마지막으로, 각 곤충 그룹별 네트워크 비교가 필요할 수 있다. 각 곤충별 네트워크가 다르지만, 유사한 구조를 공유한다는 가정 하에 조인트 그래피컬 라쏘(Joint graphical lasso)를 적용할 수 있다. 그러나 현재 각 그룹별 관측치가 적어 추정에서 오류가 발생하였고, 또한 위 두 방법에 비해 추정 시간이 폭증하는 현상이 존재해 분석에 현실적인 어려움이 존재한다.

References

- Rina Foygel and Mathias Drton. Extended bayesian information criteria for gaussian graphical models. *Advances in neural information processing systems*, 23, 2010.
- Jerome Friedman, Trevor Hastie, and Robert Tibshirani. Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3):432–441, 2008.
- Han Liu, John Lafferty, and Larry Wasserman. The nonparanormal: semiparametric estimation of high dimensional undirected graphs. *Journal of Machine Learning Research*, 10(10), 2009.